

Table Of Contents:

- [今日工作](#)
- [视觉学习和推理](#)
 - [计算机视觉问题的解决方案的构成](#)
 - [判别模型介绍](#)
 - [生成模型介绍](#)
 - [二值分类的示例](#)
 - [判别模型](#)
 - [生成模型](#)
 - [总结](#)

今日工作

- 1、阅读《计算机视觉 模型、学习和推理》第6章——视觉学习和推理。
- 2、编程练习。

视觉学习和推理

本章是书中的第二部分的第一章，第二部分的主题是**机器视觉的机器学习**。

本章阐述**测量图像与真实场景内容**相关的分类模型。

并且将模型分为两类：**生成模型**和**判别模型**。

我们的任务是通过观测的图像数据，判断内容的状态。

例如输入 x 是图片中汽车的像素个数， ω 是汽车的尺寸。

我们建立模型，并且通过图片中汽车的像素个数预测汽车的尺寸。

计算机视觉问题的解决方案的构成

模型：在数学上，将视觉数据 x 和全局状态 ω 关联起来。模型指定 x 与 ω 之间一系列可能的关系。

使用模型参数 θ 确定这一关系。

学习算法：用成对的训练样本 $\{x_i, \omega_i\}$ 来拟合参数 θ 。

推理算法：根据新的观测值 x ，利用模型来返回全局状态 ω 对应的后验概率 $\Pr(\omega|x, \theta)^*$ 。

(有可能返回MAP解或者从后验中抽样)

判别模型介绍

建立在数据 $\Pr(\omega|x)$ 上的全局状态可能模型。

要建立的模型： $\Pr(\omega|x)^*$ 。

首先，我们选择一个适合 ω 的分布 $\Pr(\omega)$ ，分布的参数是 θ 。

θ 的取值是关于 x 的函数。

因此 $\Pr(\omega)$ 返回的值与 x 和 θ 有关。将其写为 $\Pr(\omega|x, \theta)$ ，将其称为**后验分布**。

学习的目标：利用训练数据 $\{x_i, \omega_i\}$ 拟合参数 θ 。这可以通过最大似然、最大后验或贝叶斯方法得到。

推理的目标：对新的观测值 x 求出关于可能的全局状态 ω 的一个分布。

推理的过程：直接通过经过学习的模型 $\Pr(\omega|x, \theta)$ 得到。

生成模型介绍

建立在全局状态 $\Pr(x|\omega)$ 上的数据可能性模型。

要建立的模型： $\Pr(x|\omega)^*$ 。

首先，选择关于数据分布 $\Pr(x)$ 的形式，将分布参数 θ 设为 ω 的函数。

函数 $\Pr(x)$ 返回的值与 ω 和 θ 有关，将其记为 $\Pr(x|\omega, \theta)$ ，将其称为**似然函数**。

学习的目标：拟合参数 θ 。

推理的目标：计算**后验分布** $\Pr(\omega|x)^*$ 。

推理的过程：

$$\Pr(w | \boldsymbol{x}) = \frac{\Pr(\boldsymbol{x} | w) \Pr(w)}{\int \Pr(\boldsymbol{x} | w) \Pr(w) dw}$$

$$\Pr(w | x) = \frac{\Pr(x | w) \Pr(w)}{\Pr(x)} = \frac{\Pr(x, w)}{\Pr(x)}$$

二值分类的示例

条件:

观测值 x 连续。

状态 ω 二值: 0, 1。

判别模型

定义全局状态 $\omega \in \{0, 1\}$ 的一个概率分布 $Pr(\omega)$ 。

状态 ω 表示成功的概率, $\lambda \in [0, 1]$, $Pr(\omega=1)=\lambda$ 。

λ 是关于 x 的函数, 建立 x 的线性函数 $\phi_0 + \phi_1 x$ 。

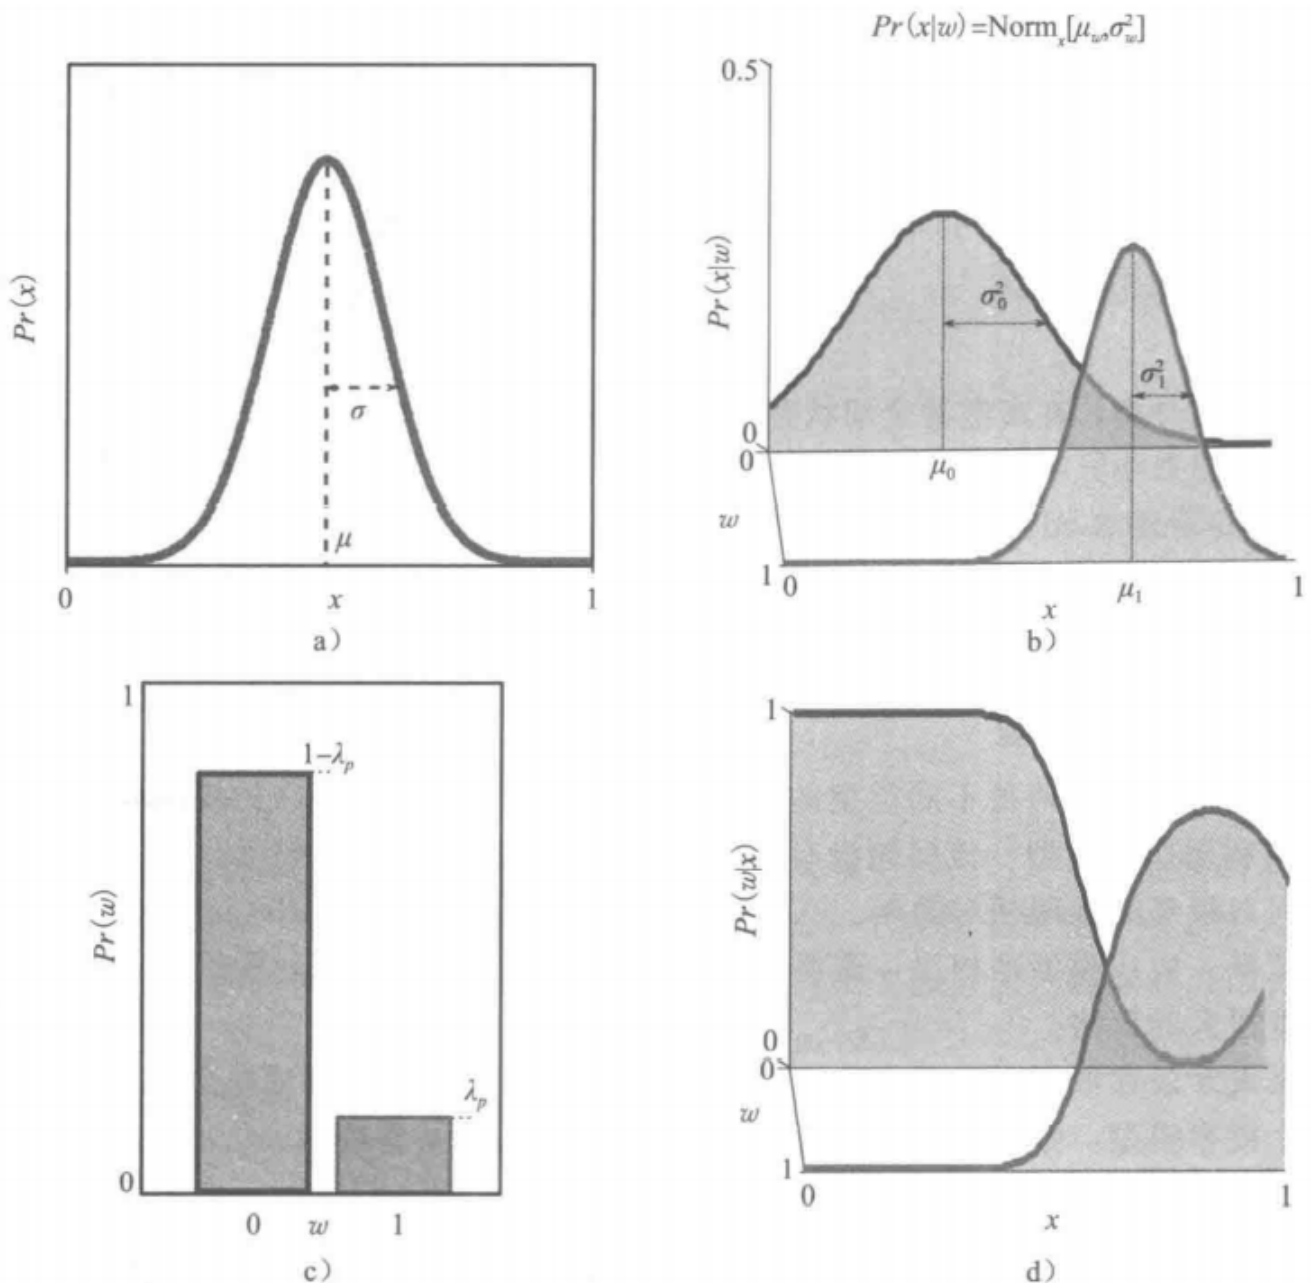
因为 $\lambda \in [0, 1]$, 使用 `sigmoid` 函数将 $\phi_0 + \phi_1 x$ 函数的值映射到 $[0, 1]$ 。

生成模型

选取数据 x 的一个概率分布 $Pr(x)$, 参数 θ 依据全局状态 ω 而定。

因为 x 是一元连续的, 选取正态分布。

正态分布的参数均值、方差为 ω 的函数。



通过对似然函数 $Pr(x|w)$ 建模来分类(生成模型)。

a) 选取一正态分布来表示数据 x_0 。

b) 令该正态分布的参数 $\{\mu, \sigma^2\}$ 为全局状态 w 的函数。在实际情况下，这意味着在全局状态 $w=0$ 时使用一组均值和方差，在 $w=1$ 时使用另一组均值和方差。学习算法根据训练样本对 $\{x_i, w_i\}_i' = 1$ 来拟合参数

$$\theta = \{\mu_0, \mu_1, \sigma_0^2, \sigma_1^2\}.$$

c) 也将全局状态 w 的先验概率建模为参数为 λ 的伯努利分布。

d) 在推理时，选取一新数据 x 并根据贝叶斯法则计算状态的后验 $Pr(w|x)$ 。

在实际情况下，这意味着当全局状态为 $w=0$ 时有一组参数，当状态为 $w=1$ 时有另一组不同的参数，因此

因为它们对每种类别数据的概率密度进行了建模，将其称为**类条件密度函数**。

在学习中，分别针对 $w=0$ 和 $w=1$ 的条件，分别拟合两个分布函数 $Pr(x|w=0)$ 和 $Pr(x|w=1)$ 的参数。

通过训练全局状态 w 学习 $Pr(w|x)$ 的参数 λ 。

推理,

我们需要让 $Pr(w=0|x)$ 与 $Pr(w=1|x)$ 的和为1。

总结

对比这两种模型，判别模型的推理明显更加简单。生成模型需要使用贝叶斯方法计算后验概率。

书中提到：

适用生成模型：

“

- 1、对似然 $Pr(x|\omega)$ 建模反映了数据实际是怎样产生的；全局状态通过某些物理过程产生了观测数据(通常光来自于光源，与物体相互作用并被相机捕获)。如果我们想建立关于模型中生成过程的信息，该方法更适合。例如，我们可以考虑诸如透视投影和遮挡等现象。使用其他方法很难发觉这种知识：本质上，我们需要从数据中重新学习这些现象。
- 2、在一些情况下，训练或测试数据向量 x 中的某些部分可能丢失。在这里，首选生成模型。它们对在所有数据维度上的联合分布建模，并能有效地插入丢失的元素。
- 3、生成模型的一个基本特性是它允许以先验的方式合并专家知识。在判别模型中很难以主要的方式施加先验知识。

“

值得注意的是，生成模型在视觉应用中更加普遍。因此，本书剩下大部分章节中主要讨论的是生成模型。

在判别模型中，我们只需要选定 ω 的分布，分布参数由 x 决定。

而在生成模型中，我们需要选定 x 的分布 $Pr1$ ， $Pr1$ 的参数由 ω 决定。

再选定 ω 的分布 $Pr2$ ， $Pr2$ 的参数通过拟合数据样本中 ω 分布情况得到。

由于 $Pr1(x)$ 与 ω 有关，因此记为 $Pr(x|\omega)$ ， $Pr2(\omega)$ 可以直接记为 $*Pr(\omega)*$ 。