

Table Of Contents:

- [今日工作](#)
- [拟合概率模型](#)
 - [最大似然法\(ML\)](#)
 - [最大后验法\(MAP\)](#)
 - [贝叶斯方法](#)
 - [示例](#)
 - [最大似然法](#)
 - [总结](#)
- [代码分析](#)

今日工作

- 1、阅读《计算机视觉 模型、学习推理》第四章：拟合概率模型 和第五章：正态分布。
- 2、分析之前代码中一些不太明白的函数的功能。

拟合概率模型

x_1, x_2, \dots, x_I 是从独立抽样得到的数据。

x^* 是新数据点，讨论 x^* 在拟合的概率模型下的概率。

θ^* 是拟合的概率模型的参数。

最大似然法(ML)

当 $Pr(x_1 \dots I | \theta)$ 最大时，这个 θ 就是 θ^* 。

这个方法理解为，为 θ 赋值，计算在这个条件下，抽样得到 x_1, x_2, \dots, x_k 这组数据的概率。

当这个概率最大时，表示原分布与 θ 条件下的分布非常相似。

数据点 θ^* 的估计概率密度是 $Pr(x^* | \theta^*)$ 。

$$\begin{aligned}\hat{\theta} &= \underset{\theta}{\operatorname{argmax}} [Pr(\mathbf{x}_{1 \dots I} | \theta)] \\ &= \underset{\theta}{\operatorname{argmax}} \left[\prod_{i=1}^I Pr(x_i | \theta) \right]\end{aligned}$$

最大后验法(MAP)

最大后验估计是最大化参数的后验概率 $Pr(\theta | x_1 \dots I)^*$ 。

在MAP拟合中，引入了参数 θ 的先验信息 $Pr(\theta)^*$ 。

因为 $Pr(x_1 \dots I)$ 与 θ 无关，因此最大值位置与分母无关，则

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} \left[\prod_{i=1}^I Pr(x_i | \theta) Pr(\theta) \right]$$

最大似然法是最大后验法在先验信息 $Pr(\theta)^*$ 未知情况下的特例。

在最大后验法中，分布函数的参数 θ 的分布函数的参数是给定的。

例如正态分布，它的共轭正态逆伽马分布的参数 $\alpha, \beta, \gamma, \delta$ 是给定的。

贝叶斯方法

贝叶斯方法基于一个事实：

有多个参数 θ 符合抽样数据的分布。

基于上述的多个参数 θ ，估计点 x^* 的概率密度：

$$\Pr(x^* | x_{1...I}) = \int \Pr(x^* | \theta) \Pr(\theta | x_{1...I}) d\theta$$

其中， $\Pr(\theta | x_{1...I})$ 的值为：

$$\Pr(\theta | x_{1...I}) = \frac{\prod_{i=1}^I \Pr(x_i | \theta) \Pr(\theta)}{\Pr(x_{1...I})}$$

注意，这个公式中出现了共轭性。先验信息 $\Pr(\theta)$ 的值由分布函数的共轭给出。

对于正态分布：

其中， k 是一个常数。

这里对应了前一章关于共轭性的内容。

示例

最大似然法

以正态分布的数据举例：

可以看出，图c中的参数是对抽样数据拟合得最好的。

$L = \Pr(x_1 \dots x_I | \theta)$ 在 θ 位置取得最大值。同时也是极值。

总结

书中介绍了三种拟合方法，针对每种方法，给出了对应的算例，通过算例，对拟合过程有了更清晰的认识。

总的来说，拟合是根据已有的抽样数据，求新数据出现的概率。

ML 合 MAP 方法需要求得这个拟合的分布的具体参数 θ ，

贝叶斯方法 基于条件：有多个 θ 符合抽样数据，然后用类似加权的方法，求得新数据出现的概率。

代码分析

最主要的工作是手动将样本整理为一批，让其能够输入模型。

使用四张三通道图像，手动构建一个batch。

并将其与通过DataLoader获得的batch对比。

除此之外还进行了`zip()`等函数的分析，内容比较杂，想到什么不理解内容的就测试了一下。