

Table Of Contents:

- [今日工作](#)
- [线性回归](#)
- [贝叶斯线性回归](#)
- [后验与先验](#)
- [线性回归拟合算法](#)

今日工作

- 1、阅读《计算机视觉 模型、学习和推理》第八章1、2节——线性回归和贝叶斯线性回归。
- 2、加深对后验分布与先验分布的理解。
- 3、编程实现书中的线性回归拟合算法。

线性回归

待求的模型：

$$Pr(w_i | x_i, \theta) = \text{Norm}_{w_i} [\phi_0 + \phi^T X_i, \sigma^2]$$

X 是数据集合，维度为 $N * D$ ， N 是数据的个数， D 是数据 x 的维度。

$$\phi = [\phi_1, \phi_2, \dots, \phi_D]^T$$

通过矩阵乘法， ϕ_i 可以理解为第 i 维的的梯度。

通过变换：

$$x_i \leftarrow (1 \quad x_i^T)^T \quad \text{和}$$

原分布可以写成：

例如1维的 X ：

变成：(50, 2)

ϕ 为：(50, 1)

1	5.9818
2	6.4648
3	5.6083
4	5.5870
5	6.1694
6	7.0114
7	5.5484
8	6.1514
9	5.7116
10	6.4357
11	5.0302

参数：

对数化不改变极值点位置。由于函数是线性的，可以通过求偏导求得极值点位置：

$$\hat{\phi} = (XX^T)^{-1} Xw$$

$$\hat{\sigma}^2 = \frac{(w - X^T \phi)^T (w - X^T \phi)}{I}$$

贝叶斯线性回归

这个方法中引入了 ϕ 的先验 $Pr(\phi)$ 。

ϕ 是多元连续的。

将 $Pr(\phi)$ 建模为均值为0，协方差为球形的多元正态分布。

根据训练样本， ϕ 的后验分布为：

似然函数为前一节线性回归 的：

根据正态分布的运算特性，后验分布可以化为以下式子：

其中：

最终，我们对 w 的预测为：

后验与先验

例子：

一个班有50个人，其中49个男的，1个女的。

在公园碰到一个同学，这个同学性别是男的概率为49/50。

如果知道这个同学穿裙子，这个同学性别是男的概率是 $p(\text{穿裙子}|\text{男生}) * 49 / 50$

这个同学是男生的**先验概率**是基于客观情况的估计即 $P(\text{男生})=49/50$

这个同学是男生的**后验概率**是 $P(\text{男生}|\text{穿裙子}) = p(\text{穿裙子}|\text{男生}) * 49 / 50$ ，即观测到一定条件后之后，一个事件的概率，同时这个条件是否能够发生本身是有一个概率。

在先验分布 $Pr(\phi)$ 中， ϕ 的分布本来是非常广的：

但是由于存在一个观测到的事实： x ，那么 ϕ 就会变窄，因为在 ϕ 这个区域内时，我们观测到 x 的概率是更高的。

线性回归拟合算法

这个算法比较简单，关键步骤是：

1、根据书中的偏导公式，可以直接计算极值点处的参数。

```
def fit_lr(X, w):
    phi = np.dot(np.dot(np.linalg.inv(np.dot(X, X.T)), X), w)
    # 正态分布均值 : phi[1, :]
    batch_size = X.shape[1]
    temp = w - np.dot(X.T, phi)
    sigma = np.dot(temp.T, temp) / batch_size
    return phi, sigma
```

2、建立一个自定义的状态 w 与 x 的线性关系。

```
phi = np.array([[7], [-0.5]])
X_phi = np.dot(X, phi)
r = np.random.randn(batch_size, 1)
for i in range(batch_size):
    mu = X_phi[i]
    w[i] = mu + r[i]
```

第一维梯度是-0.5, 7是 ϕ_0 , $r[i]$ 为干扰信息。

3、最后是验证, 验证思路与之前的算法相同, 从区域内均匀提取大量的点, 计算这些点的概率密度。

结果分析:

这是概率密度用热力图可视化以及数据的散点图可视化结果。

可以看出, 数据集中的地方概率密度值是更大的。