

Table Of Contents:

- [今日工作](#)
- [非线性回归](#)
  - [最大似然法](#)
  - [贝叶斯非线性回归](#)
- [贝叶斯线性回归拟合算法](#)

## 今日工作

- 1、阅读《计算机视觉 模型、学习和推理》第8章第3节——非线性回归。
- 2、实现贝叶斯线性回归的拟合算法。

## 非线性回归

之前讨论了线性模型，即状态 $\omega$ 与变量 $x$ 的关系是线性的。

但是很大情况下，是不符合线性关系的。

如果将 $x$ 的维度增加，维度增加后的变量为 $z$ ，用 $z$ 作为 $\omega$ 概率密度分布的参数，显然 $\omega$ 与 $x$ 的关系就不是线性了。

例如： $z_i = [1, x_i, x_i^2, x_i^3]$ 。

$$Pr(w_i | x_i) = \text{Norm}_{w_i} [\phi^T z_i, \sigma^2]$$

$$Pr(w_i | x_i) = \text{Norm}_{w_i} [\phi_0 + \phi_1 x_i + \phi_2 x_i^2 + \phi_3 x_i^3, \sigma^2]$$

主要是通过 $z_i = f(x_i)$ 这个非线性变换，建立 $\omega$ 与 $x$ 的非线性关系。

## 最大似然法

同样，与第一节线性回归相似，极值点处的参数(权重)可以由以下公式直接计算：

$$\hat{\phi} = (Z Z^T)^{-1} Z w$$

$$\hat{\sigma}^2 = \frac{(w - Z^T \hat{\phi})^T (w - Z^T \hat{\phi})}{I}$$

## 贝叶斯非线性回归

对比贝叶斯线性回归，贝叶斯非线性回归也只是把 $x$ 换成了 $z$ 。

$$Pr(w^* | x^*, X, w)$$

$$= \text{Norm}_{w^*} \left[ \frac{\sigma_p^2}{\sigma^2} x^{*T} X w - \frac{\sigma_p^2}{\sigma^2} x^{*T} X \left( X^T X + \frac{\sigma^2}{\sigma_p^2} I \right)^{-1} X^T X w, \right.$$

$$\left. \sigma_p^2 x^{*T} x^* - \sigma_p^2 x^{*T} X \left( X^T X + \frac{\sigma^2}{\sigma_p^2} I \right)^{-1} X^T x^* + \sigma^2 \right]$$

$$Pr(w^* | z^*, X, w)$$

$$= \text{Norm}_{w^*} \left[ \frac{\sigma_p^2}{\sigma^2} z^{*T} Z w - \frac{\sigma_p^2}{\sigma^2} z^{*T} Z \left( Z^T Z + \frac{\sigma^2}{\sigma_p^2} I \right)^{-1} Z^T Z w, \right.$$

$$\left. \sigma_p^2 z^{*T} z^* - \sigma_p^2 z^{*T} Z \left( Z^T Z + \frac{\sigma^2}{\sigma_p^2} I \right)^{-1} Z^T z^* + \sigma^2 \right]$$

## 贝叶斯线性回归拟合算法

完成了先验分布的计算，注意的点是，先验分布的均值为0，协方差为球形，先验分布的协方差为较大的值，反映先验较弱的事实，这个值由我们自己设置。

而后验分布参数的计算，也是拟合算法的关键暂时还没有完全实现。

先验分布：

